

AI 시스템 품질 개요

목차


❖ SW 품질 모델

❖ AI 시스템 품질 모델

❖ Trustworthy AI


❖ AI 시스템 8대 QA

ISO/IEC 25010:2011 System and Software Quality Model



ISO/IEC 25010:2011 Systems and software engineering -- Systems and software Quality Requirements and Evaluation (SQuaRE) -- System and software quality models


ISO/IEC 25010:2023 Product Quality Model



ISO/IEC 25010:2023 Systems and software engineering —
Systems and software Quality Requirements and Evaluation (SQuRE) — Product quality models


ISO/IEC 25059:2023 Quality Model for AI Systems

- ❖ A quality model for AI systems and is an application-specific extension to the standards on ISO/IEC 25010:2011



Trustworthy AI (AI 신뢰성)

AI 생애주기 전 과정에서 신뢰성 속성을 내재화하여 리스크를 통제하고, 일관된 품질과 책임성을 증명하는 역량



Trustworthy AI 추진 현황

주요 기관별 Trustworthy AI 프레임워크와 특징 비교

NIST



핵심 프레임워크

AI RMF 1.0 (AI 위험 관리 프레임워크)

주요 내용 및 특징

[기술적·조직적 위험관리 실천 체계]

7대 신뢰성 속성을 정의하고,
이를 달성하기 위한 조직적 프로세스
(Govern, Map, Measure, Manage)를
제시하는 실무 지침

EU



핵심 프레임워크

EU AI Act & Ethics Guidelines

주요 내용 및 특징

[포괄적 AI 법제 기반 규제 체계]

HLEG의 7대 핵심 요건을 바탕으로
AI 리스크를 4단계
(수용 불가 ~ 최소 리스크)로 분류하고,
고위험 AI에 강력한 준수 의무를 부과

OECD



핵심 프레임워크

OECD AI Principles (OECD AI 원칙)

주요 내용 및 특징

[국제 정책 원칙 및 글로벌 거버넌스 기준]

인권, 투명성, 안전성 등 5대 가치 기반
원칙을 제시하여 전 세계 국가들의
AI 정책 수립에 기초가 되는
글로벌 거버넌스 표준 제공

대한민국



핵심 프레임워크

인공지능 발전과 신뢰 기반 조성 등에 관한 기본법
(AI 기본법)
+ 국가 AI 윤리기준
+ 신뢰할 수 있는 인공지능 개발 안내서/TTA

주요 내용 및 특징

[법제·윤리·기술 가이드를 결합한 국가 AI 신뢰성 체계]

- AI 기본법: AI 산업 진흥과 신뢰 기반 조성, AI 윤리·검증·인증·투명성·안전성·고영향 AI 의무 규정
- AI 윤리기준: 인간성을 최고 가치로 하고 3대 기본원칙과 10대 핵심요건 제시
- TTA 안내서: 15개 개발 요구사항과 67개 검증항목 제공



공동 방향: 위험관리, 규제 준수, 윤리·투명성, 안전성·신뢰성 확보를 통해 Trustworthy AI를 체계화

NIST AI RMF 기준 주요 QA

NIST AI RMF 품질 속성	NIST 핵심 요건
 Privacy-Enhanced (프라이버시 강화)	생애주기 전반에서 개인의 자율성, 정체성, 존엄성을 보호하고, 데이터·모델·출력으로부터 개인이 식별되거나 민감 정보가 추론되는 위험을 관리해야 함.
 Fair — with Harmful Bias Managed (유해한 편향 관리된 공정성)	학습 데이터, 알고리즘, 조직 프로세스, 인간 의사결정 과정에서 발생 가능한 유해한 편향과 차별 위험을 식별·측정·완화해야 함. 단순한 집단 간 수치 균형만으로 공정성이 보장되는 것은 아님.
 Explainable & Interpretable (설명 가능하고 해석 가능)	AI 시스템이 어떻게 작동하는지와 특정 출력이 어떤 의미를 갖는지를 사용자의 역할·지식 수준·사용 맥락에 맞게 이해 가능하도록 제공해야 함.
 Safe (안전성)	정의된 조건에서 AI 시스템이 인간의 생명, 건강, 재산, 환경에 위험을 초래하지 않도록 설계·개발·배포·운영되어야 함.
 Secure & Resilient (안전하고 복원력 있는)	적대적 공격, 오용, 환경 변화, 예상치 못한 장애 상황에서도 기밀성·무결성·가용성을 보호하고, 기능을 유지하거나 안전하게 성능 저하·복구할 수 있어야 함.
 Accountable & Transparent (책임 있고 투명한)	AI 시스템의 설계 결정, 데이터 출처, 모델 구조, 의도된 사용 범위, 한계, 배포 및 사후 의사결정 책임을 추적 가능하고 적절한 수준으로 제공해야 함.
 Valid & Reliable (유효하고 신뢰할 수 있는)	의도된 사용 목적과 운용 조건에서 요구사항을 충족하며, 다양한 상황에서 정확하고 일관되며 일반화 가능한 성능을 지속적으로 입증해야 함. NIST에서는 신뢰성의 기반 특성으로 간주됨.

EU AI Act 기준 주요 QA

EU AI Act 품질 속성

EU AI Act 핵심 요건



Risk Management (위험관리)

고위험 AI 시스템에 대해 위험관리 시스템을 수립·구현·문서화·유지해야 하며, 이는 AI 시스템의 전체 수명주기 동안 지속적·반복적으로 운영되고 정기적으로 검토·갱신되어야 함. 의도된 사용뿐 아니라 합리적으로 예견 가능한 오용에서 발생할 수 있는 건강, 안전, 기본권 위험을 식별·분석·평가하고 적절한 완화 조치를 적용해야 함.



Data Governance (데이터 거버넌스)

학습·검증·테스트 데이터셋은 의도된 목적에 적합해야 하며, 관련성·충분한 대표성·가능한 범위의 오류 없음·완전성을 갖추어야 함. 또한 데이터 수집 과정, 출처, 전처리, 라벨링, 가정, 데이터 적합성, 편향 가능성, 데이터 결함을 관리해야 함.



Technical Documentation (기술문서화)

고위험 AI 시스템이 시장 출시 또는 서비스 개시 전에 기술문서를 작성해야 하며, 해당 문서는 최신 상태로 유지되어야 함. 기술문서는 시스템이 EU AI Act 요구사항을 충족한다는 것을 입증하고, 관계 당국과 인증기관이 적합성을 평가할 수 있도록 명확하고 포괄적인 정보를 제공해야 함.



Record-keeping / Traceability (기록관리/추적성)

고위험 AI 시스템은 수명주기 동안 주요 이벤트를 자동으로 기록할 수 있는 로깅 기능을 기술적으로 제공해야 함. 로그는 위험 상황 식별, 중대한 변경 파악, 사후 시장 모니터링, 시스템 운영 감시에 활용될 수 있어야 함.



Transparency (투명성 및 정보 제공)

고위험 AI 시스템은 deployer가 시스템 출력을 해석하고 적절히 사용할 수 있을 정도로 충분히 투명하게 설계·개발되어야 함. 또한 사용 설명서는 정확성·강건성·사이버보안 수준, 성능 한계, 의도된 목적, 잠재적 위험, 인간 감독 조치, 로그 수집·해석 방법 등을 명확하고 접근 가능한 방식으로 제공해야 함.



Human Oversight (인간의 감독)

고위험 AI 시스템은 사용 중 자연인이 효과적으로 감독할 수 있도록 적절한 인간-기계 인터페이스를 갖추어야 함. 인간 감독은 건강, 안전, 기본권 위험을 예방 또는 최소화하는 것을 목표로 하며, 시스템의 위험 수준, 자율성, 사용 맥락에 비례해야 함. 감독자는 시스템의 한계 이해, 운영 감시, 출력 해석, 결과 무시·철회·중단이 가능해야 함.



Accuracy (정확성)

고위험 AI 시스템은 의도된 목적에 적합한 수준의 정확성을 달성해야 하며, 수명주기 전반에서 일관된 성능을 유지해야 함. 정확도 수준과 관련 정확도 지표는 사용 설명서에 명시되어야 함.



Robustness (강건성/복원력)

고위험 AI 시스템은 시스템 내부 또는 운용 환경에서 발생할 수 있는 오류, 결함, 불일치에 대해 가능한 한 복원력 있게 설계되어야 함. 기술적·조직적 조치를 통해 오류 상황에서도 적절히 대응해야 하며, 필요한 경우 백업 또는 fail-safe 계획을 포함할 수 있음.



Cybersecurity (사이버보안)

고위험 AI 시스템은 취약점을 악용하여 사용, 출력, 성능을 변경하려는 비인가 제3자의 시도에 대해 복원력을 가져야 함. 데이터 포이즈닝, 모델 포이즈닝, 적대적 예제, 모델 회피, 기밀성 공격 등 AI 특화 취약점에 대한 예방·탐지·대응·해결·통제 조치를 포함해야 함.

AI 기본법 주요 QA

한국 AI 기본법 법정 QA 항목	핵심 QA 포인트
1  인공지능 투명성 확보 의무	AI 기반 운용 사실, 생성형 AI 결과물, 딥페이크성 결과물에 대해 이용자가 명확히 인식할 수 있도록 사전 고지 또는 표시하였는가?
2  고영향 인공지능의 확인	제공하려는 AI가 고영향 인공지능에 해당하는지 사전에 검토하고, 필요한 경우 과기정통부장관에게 확인을 요청하였는가?
3  고영향 인공지능의 안전성·신뢰성 확보 조치	고영향 인공지능의 안전성·신뢰성 확보를 위한 관리 조치를 체계적으로 이행하고 있는가?
4  위험관리방안의 수립·운영	AI 수명주기 전반의 위험을 식별·평가·완화하고, 운영 중 위험을 지속적으로 관리하고 있는가?
5  설명 방안의 수립·시행	최종결과, 주요 판단 기준, 학습용데이터 개요 등에 대해 기술적으로 가능한 범위에서 설명할 수 있는가?
6  이용자 보호 방안의 수립·운영	이용자 피해, 권리 침해, 오작동, 부정확한 결과 등에 대한 보호·대응 절차를 마련하였는가?
7  고영향 인공지능에 대한 사람의 관리·감독	사람이 AI 운용과 결과를 관리·감독하고 필요 시 개입·정정·중단할 수 있는가?
8  문서의 작성과 보관	안전성·신뢰성 확보 조치의 내용을 확인할 수 있는 문서를 작성하고 보관하고 있는가?
9  고영향 인공지능 영향평가	고영향 인공지능이 사람의 기본권에 미치는 영향을 사전에 평가하기 위해 노력하였는가?

AI 시스템 8대 QA

AI 시스템의 생애주기 전반에서 관리되어야 할 품질 속성

1



기능 정확성

시스템이 사용자가 의도한 정답을,
요구되는 정밀도로 제공하는 능력

2



강건성

시스템이 다양한 악조건 속에서도
기능 정확성을 유지할 수 있는 능력

3



프라이버시

시스템이 개인에 관한 데이터의
부당하거나 불법적인 수집 및 사용으로 인해
발생하는, 개인의 사생활이나 사적인
활동에 대한 침해를 방지하는 능력

4



공정성

시스템이 성별, 인종 등의 부당한
차별 없어, 기화된 규범을
존중하는 결과를 제공하는 능력

5



기능 적응성

시스템이 운영 환경의 다양한
변화에 대응하여 스스로를
적응시키는 능력

6



제어 가능성

제어 주체(Controller, 인간 또는
외부 에이전트)가 시스템의 기능
수행에 개입하여 신뢰성 회복을
지원하는 능력

7



설명 용이성

시스템이 도출한 결과에 대하여,
그 이유와 타당성을 인간이
납득할 수 있는 형태로 표현하는
시스템의 능력

8



수행 효율성

명시된 조건 하에서, 특정 시간 및
처리량 내에서 기능을 수행하고
자원을 효율적으로 사용하는 능력



8대 QA를 기반으로 AI 시스템의 신뢰성과 책임성을 체계적으로 확보

8대 QA 중요성

품질 속성	정의
 기능 정확성	시스템이 사용자가 의도한 정답을, 요구되는 정밀도로 제공하는 능력  사용자 요청 →  AI 시스템 →  정답 →  정답 일치 정밀도 충족
 강건성	시스템이 다양한 악조건 속에서도 기능 정확성을 유지할 수 있는 능력  잡음 / 노이즈 환경 변화 →  AI 시스템 →  정답 유지 →  정확성 유지
 프라이버시	시스템이 개인에 관한 데이터의 부당하거나 불법적인 수집 및 사용으로 인해 발생하는, 개인의 사생활이나 사적인 활동에 대한 침해를 방지하는 능력  개인 데이터 →  보호 / 익명화 →  안전한 활용 →  개인 정보 보호 침해 방지
 공정성	시스템이 성별, 인종 등의 부당한 차별 없이, 기획된 규범을 존중하는 결과를 제공하는 능력  다양한 집단 →  AI 시스템 →  공정한 결과 →  차별 없는 공정한 결과
 기능 적응성	시스템이 운영 환경의 다양한 변화에 대응하여 스스로를 적응 시키는 능력  환경 변화 감지 →  스스로 학습 / 조정 →  성능 유지 / 향상 →  변화에 적응하여 지속적 성능 유지
 제어 가능성	제어 주체(Controller, 인간 또는 외부 에이전트)가 시스템의 기능 수행에 개입하여 신뢰성 회복을 지원하는 능력  제어 주체 →  개입 / 조작 →  신뢰성 회복 →  안전하게 제어 가능
 설명 용이성	시스템이 도출한 결과에 대하여, 그 이유와 타당성을 인간이 납득할 수 있는 형태로 표현하는 시스템의 능력  AI 결과 →  설명 생성 →  사용자 이해 / 납득 →  설명 가능 / 납득 가능
 수행 효율성	명시된 조건 하에서, 특정 시간 및 처리량 내에서 기능을 수행하고 자원을 효율적으로 사용하는 능력  시간 / 처리량 →  효율적 수행 →  자원 효율적 사용 →  효율적 성능 / 자원 사용

도로 객체 인식 동작

AI 시스템 8대 QA 관점의 요구사항 예시

1

기능 정확성



전방에 정지한 차량과 그림자를 명확히 구분하여 99.9% 이상의 정밀도로 인식해야 한다.

2

강건성



폭우, 폭설 또는 야간의 역광 상황에서도 보행자 및 장애물 인식 성능을 일정 수준 유지해야 한다.

3

프라이버시



사물 인식 과정에서 수집되는 주변 차량의 번호판이나 행인의 얼굴을 실시간으로 비식별화 처리해야 한다.

4

공정성



보행자의 연령, 성별, 인종 또는 휠체어 사용 여부와 관계없이 동일한 수준의 인식 정확도를 보장해야 한다.

5

기능 적응성



공사 구간이나 새로운 형태의 표지판이 등장했을 때, 업데이트를 통해 해당 환경에 즉각 대응해야 한다.

6

제어 가능성



시스템이 사물을 잘못 인식하여 급제동할 경우, 운전자가 즉시 개입하여 시스템을 수동 제어로 전환할 수 있어야 한다.

7

설명 용이성



특정 장애물을 인식하여 멈췄을 때, 해당 물체를 '보행자'로 판단한 시각적 근거(BBox 등)를 로그로 제공해야 한다.

8

수행 효율성



차량 내 한정된 컴퓨팅 자원을 활용해 초당 30프레임 이상의 실시간 사물 인식 속도를 유지해야 한다.



도로 객체 인식의 신뢰성은 **정확성, 강건성, 안전한 제어, 설명 가능성, 실시간 성능**을 균형 있게 확보할 때 달성된다.

AVN/공조 장치에 대한 음성 제어

AI 시스템 8대 QA 관점의 요구사항 예시

1 기능 정확성



"에어컨 23도로 맞춰줘"라는 음성 명령을 수신했을 때, 오차 없이 정확히 23도로 설정해야 한다.

2 강건성



고속 주행 중의 풍절음이나 창문을 열었을 때 발생하는 외부 소음 환경에서도 사용자의 명령을 식별해야 한다.

3 프라이버시



음성 인식 데이터는 차량 내부(On-device)에서 우선 처리하며, 외부 서버 전송 시 개인 식별 정보를 제거해야 한다.

4 공정성



사용자의 사투리(방언), 고령층의 느린 말투, 아이의 높은 톤 등 다양한 음성 특성에도 차별 없이 동일하게 반응해야 한다.

5 기능 적응성




사용자가 자주 사용하는 특정 명칭(예: "집으로 가자")이나 신조어를 학습하여 시간이 지날수록 인식률을 높여야 한다.

6 제어 가능성



음성 명령을 잘못 인식하여 엉뚱한 기능을 실행 중일 때, 운전자가 즉시 "취소" 명령이나 물리 버튼으로 중단할 수 있어야 한다.

7 설명 용이성



명령 인식 실패 시, "소음이 너무 커서 이해하지 못했습니다"와 같이 실패 원인을 명확한 피드백으로 제공해야 한다.

8 수행 효율성



발화가 끝난 후 0.5초 이내에 명령 해석을 완료하고 해당 장치(AVN 등)를 제어하기 위한 신호를 송출해야 한다.



음성 제어의 신뢰성은 **정확한 인식**, **소음 환경 대응**, **개인정보 보호**, **공정한 반응**, **사용자 개입**, **명확한 피드백**, **빠른 응답**을 균형 있게 확보할 때 달성된다.

AI 시스템 8대 QA 역할

QA 관점	QA 역할	QA
기능 측면 (Functional Excellence)	사용자의 '기대대로' 올바르게 동작하고, 세상의 변화에 맞춰 '진화'하는 능력	• 기능 정확성 • 강건성 • 프라이버시 • 공정성 • 기능 적응성
신뢰성 측면 (Trustworthiness)	사용자가 시스템을 '믿고' 사용할 수 있게 만드는 거버넌스 능력	• 제어 가능성 • 설명 용이성
효율성 측면 (Efficiency)	모든 기능과 신뢰성 측면에서 시스템 자원을 효율적으로 활용하는 능력	• 수행 효율성

AI 시스템 QA 요약

관점	QA	핵심 역할	목표
기능 	1 기능 정확성	 일반적 상황에서의 기본 품질	 일반적인 입력에 대해 정답을 내놓는 능력으로, 시스템의 가장 기초적인 능력임
	2 강건성	 악조건 상황에서의 견고성	 노이즈나 비정상적 입력에도 시스템이 무너지지 않고 일관된 기능 정확성을 유지하는 '방어력'임
	3 프라이버시	 프라이버시 보호	 학습 데이터에 포함된 개인의 민감 정보가 모델의 예측값이나 인터페이스를 통해 노출되지 않도록 하는 안전장치임
	4 공정성	 공정성 제공	 모델의 결과물이 특정 집단(성별, 인종 등)을 부당하게 차별하지 않고 기화된 규범을 존중하도록 하는 안전장치임
	5 기능 적응성	 지속적 진화	 물리적 환경/대상 및 사회/논리적 변화를 감지하고, 재학습 등을 통해 지속적으로 진화하는 '생존 능력'임
신뢰성 	6 제어 가능성	 신뢰성 확보	 시스템이 정상적인 동작이 아닌 경우, 외부에서 개입하여 의도한 동작을 완료시키거나 안전 상태로 전환시키는 '통제권'임
	7 설명 용이성	 신뢰성 소통	 시스템의 판단 근거를 사람이 이해할 수 있는 형태로 제공하여 결과에 대한 '신뢰'를 부여하는 '소통 창구'임
효율성 	8 수행 효율성	 수행 최적화	 추론 속도, 처리량, 자원 점유율 등 서비스 환경에서 제시간에 응답할 수 있게 하는 모든 QA 활동의 '물리적 제약 조건'임

Q & A
