

설명 용이성 **(Explainability)**

목차

- ❖ 설명 용이성 개념
- ❖ 모델의 설명 용이성 수준
- ❖ 설명 모드
- ❖ 설명 용이성 평가 기준 및 지표
- ❖ 설명 용이성 QA 시나리오

설명 용이성 개념

설명 용이성 정의

Property of an AI system that enables a given human audience to comprehend the reasons for the system's behaviour

[ISO/IEC TS 6254:2025 Objectives and approaches for explainability and interpretability of machine learning (ML) models and artificial intelligence (AI) systems]

Explainability is the property of an AI system that means that the important factors influencing a decision can be expressed in a way that humans can understand

[ISO/IEC 22989:2022 Artificial intelligence concepts and terminology]

❖ "AI 시스템이 도출한 '결과'에 대하여, 그 '이유'와 '타당성'을 인간이 납득할 수 있는 형태로 표현하는 시스템의 능력"




설명 용이성 (Explainability)

AI 시스템이 도출한 ‘결과’에 대하여, 그 ‘이유’와 ‘타당성’을 인간이 납득할 수 있는 형태로 표현하는 시스템의 능력

- 결과
- 이유
- 타당성

설명의 대상
시스템 동작 메커니즘 수준으로 설명
사회적·제도적 근거 수준으로 설명

예시 상황



1 결과

설명의 대상

자율주행차가 시속 60km로 주행하다
전방의 검은 물체를 감지하고
'0.5초 이내에 급제동(Emergency Braking)'을
수행하여 정지한 상태임



2 이유

결과를 시스템 동작 메커니즘 수준으로 설명

전방 LiDAR 및 카메라 센서가 20m 거리에서
물체와의 상대 속도 감감을 감지함.
제어 알고리즘이 충돌 위험 지수가 임계치(0.6초)
이하임을 판단하고, 조향 대신 최대 유압 브레이크를
즉시 활성화하여 물리적 정지를 유도함



3 타당성

결과를 사회적 근거 지식 및 제도적 근거 수준으로 설명

근거 지식

학습 데이터셋
패턴 일치도
99.8%

물리 시뮬레이션 결과
생존 확률 비교

- 해당 물체의 외곽선 및 반사를 데이터가 학습 데이터셋 내 '보행자' 혹은 '고정 장애물' 패턴과 99.8% 일치함.
- 물리 법칙상 60km 속도에서 충돌을 피하기 위한 유일한 생존 확률 경로가 급제동임을 입증함.

급제동 경로 (생존 확률 99.1%)

조향 회피 경로 (생존 확률 3.2%)

제도적 근거

ISO 26262 (기능 안전성)

SAE J3016 (자율주행 단계 분류 및 가이드라인)

- ISO 26262(기능 안전성) 및 SAE J3016 표준의 비상 제동 가이드라인을 준수함.
- 사고 시 '인명 보호 최우선 원칙'에 따라 승객의 일시적 불편(급정거 충격)보다 타인의 생명권 보호를 우선시한 윤리적 설계 지침에 부합함.



핵심 요약

결과(무엇을 했는가?)

급제동으로 정지함

+

이유(어떻게 판단·동작했는가?)

센서 감지 → 위험 판단 → 제어 실행

+

타당성(왜 그렇게 하는 것이 정당한가?)

근거 지식 + 제도적 근거

=

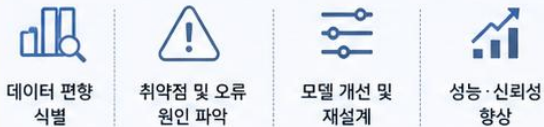

인간이 납득할 수 있는 설명



XAI 필요성

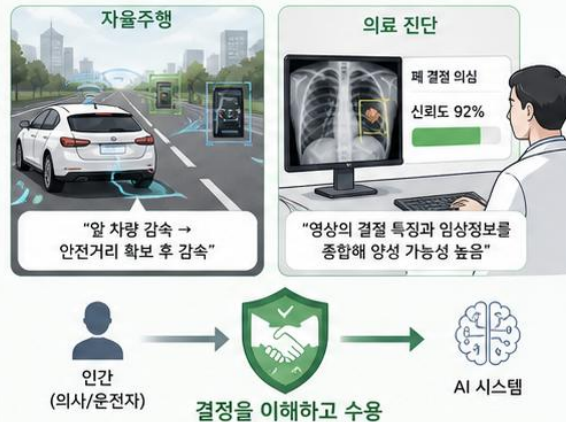
1 디버깅 및 최적화 (Advanced Debugging)

설명 기능을 통해 학습 데이터의 편향이나 모델의 취약점을 찾아내어 모델의 신뢰성을 개선할 수 있음



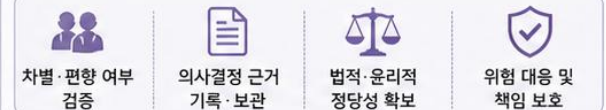

2 신뢰의 도구 (Trust Enabler)

자율주행이나 의료처럼 Critical한 분야에서 인간이 AI의 결정을 수용하게 만드는 수단임



3 법적·윤리적 방어권 (Legal Defense)

금융이나 사법 분야에서 AI의 결정이 차별적이지 않았음을 입증하는 정당성(Justification)의 근거가 됨



분야별 XAI 필요 예



의료

[진단 결과에 대한 신뢰성]

의료 데이터를 분석하여
의사의 의사결정을 지원하고,
예방적 조치를 가능하게 함.



대표 설명 예시

- 의료 영상 내 미세 이상 징후 식별 및 근거 제시
- 약물 반응 예측 결과에 대한 근거 제시



금융

[규제 준수 및 공정성]

공정 대출 정책을 준수하고,
데이터 편향을 제거하여 금융 기관의
법적 책무를 다하기 위함.



대표 설명 예시

- 의심 거래 탐지 시 알람 발생 원인 설명
- 대출 승인/거절 사유의 투명한 공개



자율주행

[사용자 신뢰]

생명과 직결된 안전 관련 결정의 이유를
사용자에게 납득시켜 시스템에 대한
신뢰를 구축함.



대표 설명 예시

- 급제동 등 차량의
특정 행동에 대한 상세한 설명



국방

[전략적 통제 및 관리]

군 관계자가 자율 시스템을 효과적으로
관리하고, 시스템의 판단을
신뢰하기 위함.



대표 설명 예시

- 자율 무기 체계 및 전투 시스템의
동작 근거 제시



의료: 신뢰성



금융: 공정성·규제



자율주행: 안전·신뢰



국방: 통제·관리

설명 용이성 관련 개념



AI 모델의 설명 용이성 수준


높은 설명 용이성 모델

규칙이 명시적이고 내부 로직을 추적할 수 있는 모델들

대상



규칙 기반 알고리즘
(Rule-based)



기호 논리
(Symbolic methods)



결정 트리
(Decision trees)



명시적인 규칙과 구조를 통해
판단 과정을 직접 추적할 수 있음

특징


모델 자체가 가진 규칙(Rule)이 곧
판단의 근거가 되므로 설명 설성이
매우 자연스럽게 명확함



- ✓ 왜 그런 결정을 했는지 추론 경로 제시 가능
- ✓ 판단 기준이 명시적임
- ✓ 검증과 수정이 상대적으로 쉬움

한계

모델의 규모가 커지고 복잡해질수록
규칙은 존재하지만 인간이 한눈에
이해하기에는 한계가 발생할 수 있음



- ⚠ 규칙 수가 많아지면 가독성 저하
- ⚠ 설명 가능하지만 항상 쉽게 이해되는 것은 아님
- ⚠ Explainable ≠ Always Understandable



핵심 요약: 높은 설명 용이성 모델은 판단 근거가 명시적이어서 설명에는 강하지만,
복잡성이 증가하면 **인간의 이해 용이성은 낮아질 수 있음.**

낮은 설명 용이성 모델

낮은 설명 용이성 모델

내부 연산 과정이 복잡한 수학적 행렬로 이루어져 직관적인 이해가 어려운 모델들



대상

딥러닝(Deep Learning),
심층 신경망(Neural Networks) 등



특징


수조 개의 파라미터와 비선형적인 연산 구조 때문에
시스템이 어떻게(How) 최종 결정에 도달했는지에 대해
의미 있는 설명을 제공하기가 매우 어려움



해결 방향

내재적 해석이 어렵기 때문에, 별도의 도구
(SHAP, LIME 등)를 활용하여 사후에 근거를 추출하는
XAI 기법이 필수적으로 요구됨

예시: 이미지 분류 모델(고양이 판별) 내부 구조




별도의 XAI 도구를 통한 사후 설명(근거 추출)

1. SHAP (SHapley Additive exPlanations)

특징

각 특징이 예측에 기여한 정도를
SHAP 값으로 계산하여 설명

고양이 예측(0.92)에 대한 SHAP 값 예시



설명 시각화 예시




빨간색: 예측에 긍정적 기여
파란색: 예측에 부정적 기여

2. LIME (Local Interpretable Model-agnostic Explanations)

특징

해당 예측 주변의 유사 데이터를 생성하여
단순 모델(선형 모델 등)로 근사해 설명

입력 공간에서의 LIME 근사 예시




설명 예시

주변 데이터를 기반으로 단순 모델을 학습하여,
각 특징의 영향력을 선형적으로 설명

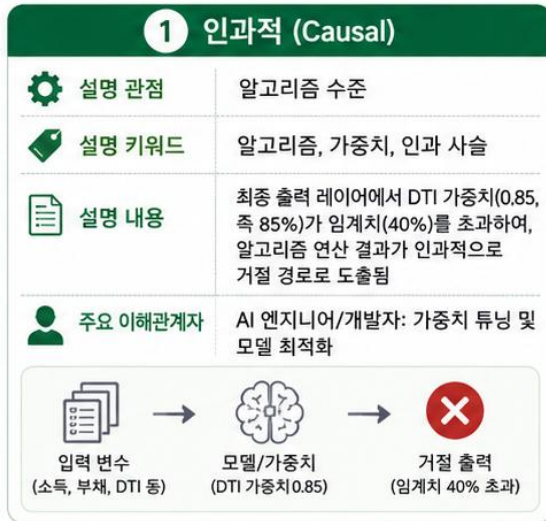
특징	영향도(가중치)
귀 모양이 뽀족함	+0.42
수염이 보임	+0.31
눈이 둥글고 큼	+0.21
배경이 실내	-0.10
어두운 색 털	-0.06

설명 유형(MODE OF EXPLANATION)

설명 유형(Mode of Explanation)

설명 유형	핵심 질문	설명 수준	설명 관점	관련 개념	주요 이해관계자
 인과적 (Causal)	 시스템이 어떻게 작동하는가?	시스템 중심 	알고리즘 작동 메커니즘, 인과적 추적 	Interpretability 	개발자, 엔지니어 
 인식적 (Epistemic)	 이 결과가 왜 사실인가?	사회적 사실/원칙 	현실 세계 논리/사실 	Truthfulness 	도메인 전문가, 데이터 사이언티스트 
 정당성 (Justificatory)	 어떤 근거로 정당화되는가?		사회적 원칙, 윤리 기준, 법적 규제 및 표준 	Accountability 	사용자, 규제기관 
 핵심 요약	설명은 누구에게, 무엇을, 어떤 관점에서 전달하느냐에 따라 세 가지 유형으로 구분됩니다. 인과적 설명은 시스템의 작동 원리를, 인식적 설명은 결과의 사실성을, 정당성 설명은 사회적·윤리적 정당성을 제공합니다.				

대출 승인 거절 시나리오



자율주행 급정거 시나리오




사례: 자율주행차가 전방 위험 요소를 감지하고 급정거

핵심 상황:
장애물 인식 → 비상 제동

같은 사건이라도 이해관계자와 관점에 따라 설명 방식이 달라집니다.

1 인과적 (Causal)

설명 관점	알고리즘 수준
설명 키워드	센서 데이터, 가중치, 제어 로직
설명 내용	LiDAR 센서 데이터와 신경망 가중치 분석을 통해 장애물을 분류하고, 시스템 내부 로직에 따라 비상 제동 명령을 인과적으로 출력함
주요 이해관계자	개발자: 시스템 디버깅



2 인식적 (Epistemic)

설명 관점	현상학적 수준
설명 키워드	물체 인식 논리, 상황적 타당성
설명 내용	물리적 모델과 학습 데이터를 기반으로 전방 물체를 위험 요소로 인지하였으며, 이는 현실 세계의 위험 회피 원칙에 비추어 진실된 판단임을 입증함
주요 이해관계자	사고 조사관: 판단의 진실성 확인



3 정당성 (Justificatory)

설명 관점	사회/법적 수준
설명 키워드	안전 표준(ISO), 윤리 규정, 법규
설명 내용	ISO 26262 및 윤리 가이드라인의 안전 우선 원칙을 준수하였으며, 관련 법규와 제조사 정책에 근거하여 사회적으로 정당한 조치임을 증명함
주요 이해관계자	법원/보험사: 책임 소재 및 정당성 판정



한눈에 요약

1 인과적 (Causal):
시스템 내부 작동 설명

2 인식적 (Epistemic):
현실 세계 사실성과 타당성 설명

3 정당성 (Justificatory):
사회적·법적 정당성 설명

설명 용이성 평가 기준

설명 용이성 평가 기준 유형

구분	핵심 가치	평가 질문	평가 기준
기술적 신뢰성	정확성	"이 설명을 믿어도 되는가?"	정합성, 충실성, 재현성, 강건성
사용자 경험	이해 수준	"이 설명이 나에게 유용한가?"	가독성, 시뮬레이션 가능성, 실행 가능성

설명 용이성 평가 기준 유형

기술적 신뢰성 관점 평가 기준



평가 기준	평가 기준 설명
 정합성	사용자의 구체적인 목적과 논리적으로 부합
 충실성	실제 모델의 판단 로직을 오차 없이 반영할 만큼 충실
 재현성	동일한 조건에서 항상 일관된 결과를 출력함
 강건성	사소한 환경 변화에도 흔들림 없는 안정적인 신뢰를 유지

사용자 경험(UX) 관점 평가 기준





평가 기준	평가 기준 설명
 가독성	사용자가 제시된 설명을 인지적 노력 없이 쉽게 이해할 수 있어야 함
 시뮬레이션 가능성	설명된 원리를 바탕으로 새로운 사례의 결과를 스스로 예측할 수 있을 만큼 명확해야 함
 실행 가능성	사용자가 당면한 문제를 해결하기 위한 구체적인 후속 조치를 결정하는 데 실질적인 도움이 되어야 함

설명 용이성 평가 기준 유형: 설명 예

평가 관점	평가 기준	설명 예
 기술적 신뢰성 관점 평가 기준	 정합성	"대출 거절 사유가 '낮은 소득'이라는 금융 도메인의 상식과 일치하는가?"  도메인 상식 → 대출 거절 사유 : 낮은 소득 
	 충실성	"모델이 판단에 가장 큰 가중치를 둔 변수를 설명에서도 1순위로 제시하는가?" 변수 중요도 (모델) 1. DTI 0.45 2. 소득 0.25 3. 신용점수 0.15 → 설명 (SHAP) 1. DTI 2. 소득 3. 신용점수
	 재현성	"동일한 데이터로 다시 설명 요청을 보냈을 때, 이전과 똑같은 SHAP 값을 출력하는가?" 1차 설명 결과 (SHAP 값) DTI 0.45, 소득 0.25, 신용점수 0.15 ... = 2차 설명 결과 (SHAP 값) DTI 0.45, 소득 0.25, 신용점수 0.15 ...
	 강건성	"소득이 1원 변하는 정도의 미세한 노이즈에도 설명의 주요 순위가 유지되는가?" 원본 데이터 소득: 4,000만원 → 1. DTI 2. 소득 3. 신용점수 ← 노이즈 데이터 (+1원) 소득: 4,000만원 +1원
 사용자 경험(UX) 관점 평가 기준	 가독성	"수천 개의 변수 나열 대신 '상위 3가지 핵심 요인'을 막대 그래프로 시각화하였는가?" 비효율적 설명 (예) 변수1, 변수2, 변수3, ..., 변수999 변수1000, 변수1001, → 효과적 설명 (예) 1. DTI 0.45 2. 소득 0.25 3. 신용점수 0.15
	 시뮬레이션 가능성	"설명을 본 사용자가 '소득이 10% 늘면 대출이 승인되겠군'이라고 결과를 예측할 수 있는가?" 현재 상태 소득: 4,000만원 → 거절 확률: 80% → 소득 +10% 증가 소득: 4,400만원 → 거절 확률: 30% → 예측 결과 → 승인 가능성 높음!
	 실행 가능성	"'부채가 많음' 대신 '카드 잔액을 500만 원 이하로 줄이면 승인 확률이 높음'을 제시하는가?" 추상적 설명 (예) 부채가 많음 → 실행 가능한 설명 (예) 카드 잔액을 500만 원 이하로 줄이면 승인 확률이 높아집니다.

설명 용이성 평가 지표

기술적 신뢰성 평가 지표

평가 기준	평가 지표		의미
 정합성 설명 목적과 시스템 구현의 논리적 부합성 검사	 요구사항 충족률	$\text{충족률}(\%) = \frac{\text{구현된 설명 요구사항 수}}{\text{전체 설명 요구사항 수}} \times 100$	설계 단계에서 정의된 설명 목적 (인과·인지·정당성)의 시스템 구현 완전성 검증
	 정보 일치도 점수	 일치도 점수 (0~1)	사용자 맥락 및 질의 의도와 제공된 설명 정보 간의 논리적 부합성 측정
 충실성 설명이 원본 모델의 판단 로직을 얼마나 정확하게 반영하는지 평가	 설명 일치도		설명 모듈이 원본 모델의 판단 로직을 왜곡 없이 요약·전달하는 정직성 정량화
	 국소적 근사 오차	 $\text{오차 (MAE/RMSE)} = \dots \rightarrow \downarrow$	국소 대리 모델(Surrogate)이 원본 모델의 결정 경계를 묘사하는 기술적 정밀도 측정
 재현성 동일 조건에서 설명 결과가 일관되게 재현되는지 평가	 설명 안정성 지수	 분산 ↓	알고리즘 내부 무작위성에 따른 결과 변동성 억제 및 출력 일관성 검증
	 동일 입력 일치율	 일치율(%)	동일 입력값에 대한 결정론적 동작 여부 및 출력 리포트의 일치율 측정
 강건성 입력 변화에 대해 설명이 얼마나 안정적으로 유지되는지 평가	 설명 민감도 비율	 $\text{민감도} = \frac{\text{변화량}}{\text{입력 변화량}}$	입력 데이터의 미세 변화(Noise)에 대한 설명 결과의 수치적·논리적 안정성 평가
	 변화 동기화율	 동기화율(%)	모델 예측 결과의 변화와 설명 내용의 변화 간 상호 논리적 동기화 수준 측정

사용자 경험 평가 지표

평가 기준	평가 지표	의미	시각적 예시
 가독성 (Readability)	 설명 복잡도	인지적 한계 내 정보 전달의 효율성 및 사용자 인지 부하 수준 측정	복잡한 설명 (높은 인지 부하) 신용점수, DTI, 연체정보, 소득수준, 부채비율, 거래실적, 신용이력기간, 카드사용패턴, 금융기관평가등... → 간결한 설명 (낮은 인지 부하) 상위 3가지 핵심 요인 1. DTI 0.45 2. 소득 0.25 3. 신용점수 0.15
	 정보 습득 시간	시각화 및 간결화 전략에 따른 사용자 의사결정 속도 향상도 측정	기존 설명 (긴 시간)  90초 → 개선된 설명 (짧은 시간)  25초
 시뮬레이션 가능성 (Simulatability)	 인간 예측 정확도	사용자 멘탈 모델 형성을 통한 AI 판단 로직의 이해 수준 검증	설명 제공 후 사용자의 예측 정확도 설명 제공 전 38% → 설명 제공 후 76%  76%
	 예측 확신도 일치율	모델의 강점 및 약점에 대한 사용자 인지 수준과 실제 모델 지표 간의 일치성 측정	사용자 확신도와 모델 실제 성능의 일치 사용자 예측 확신도 (예: 높음) ↔ 일치도 모델 실제 정확도 (예: 78%)  일치율 82%
 실행 가능성 (Actionability)	 대안 유효성 비율	제시된 개선 가이드라인(반사실적 설명 등)의 기술적 유효성 및 실제 작동 여부 검증	제안 대안의 유효성 검증 제안: DTI 0.45 → 0.35 (소득 증가 또는 부채 감소) → 결과: 승인 확률 45% → 72%  유효성 비율 80%
	 실행 제약 준수율	현실적 제약 조건(수정 불가능 변수 제외)을 반영한 대안의 실질적 실천 가능성 측정	현실 제약 조건 반영 여부  수정 가능 변수 (소득, 부채 등)  수정 불가능 변수 (나이, 과거 연체 등)  준수율 93%
	 정보 구체성 지수	즉각적인 후속 조치를 돕는 구체적 수치 및 지침 정보의 밀도 측정	구체적이고 실행 가능한 정보 제공 정도 추상적 표현 "부채를 줄이세요" → 구체적 지침 "카드 잔액을 500만원 이하로 줄이세요" 구체성 지수 (예시) 0.87

설명 용이성 QA 시나리오

설명 용이성 QA 시나리오

항목	설명
Source	사용자, 서비스 운영자 개발자, 도메인 전문가 사고 조사관
Stimulus	사용자가 AI 시스템의 결과에 대한 설명을 요청함 결과 예시: 예측, 분류, 추천, 경고, 제어 명령, 거절 판단, 위험 판단 등
Artifact	AI-based system, AI 시스템
Environment	정상 운영 상황
Response	인과적 설명, 인식적 설명, 정당성 설명 시스템은 AI가 산출한 결과에 대해 입력 데이터, 주요 영향 요인, 모델 판단 근거, 도메인 지식, 정책·윤리·법적 기준을 바탕으로 이해관계자 수준에 맞는 설명을 생성하고 제시함
Measure	기술적 신뢰성 평가 관점: 정합성, 충실성, 재현성, 강건성 사용자 경험 평가 관점: 가독성, 시뮬레이션 가능성, 실행 가능성 설명 수행 효율성

대출 심사 거절에 대한 설명 요구사항

항목	설명
Source	대출 신청자
Stimulus	AI가 대출 신청을 거절하였고, 신청자가 거절 사유에 대한 설명을 요청함
Artifact	대출 심사 AI 시스템
Environment	금융 서비스 운영 중
Response	시스템은 대출 거절 결과에 대해 주요 영향 요인, 예를 들어 DTI 초과, 최근 연체 이력, 신용 점수 하락 등을 제시하고, 해당 판단이 금융 리스크 기준 및 공정 대출 원칙에 부합함을 설명함
Measure	정보 일치도 점수 90% 이상, 동일 입력 일치율 100% 인간 예측 정확도 80% 이상, 실행 가능한 개선 조치 제시 여부

자율주행 급제동에 대한 설명 요구사항

항목	설명
Source	사고 조사관
Stimulus	자율주행차가 주행 중 전방 장애물을 감지하고 급제동을 수행함. 사고 조사 과정에서 급제동 이유와 정당성 설명이 요구됨
Artifact	자율주행 AI 시스템
Environment	사고 조사 및 책임 판단 상황
Response	시스템은 LiDAR·카메라 데이터, 객체 인식 결과, 충돌 예상 시간, 제어 알고리즘의 판단 경로를 바탕으로 급제동 이유를 설명하고, 안전 우선 원칙 및 관련 표준에 따른 정당성을 제시함
Measure	설명 일치도 90% 이상, 동일 입력 일치율 100%, 인간 예측 정확도 80% 이상

Q & A
